# Comment tester et optimiser la performance d'un SI ?



18 janvier 2016

#### Marc BOJOLY

OCTO Technology Paris, manager et consultant Co-fondateur du Performance User Group Paris

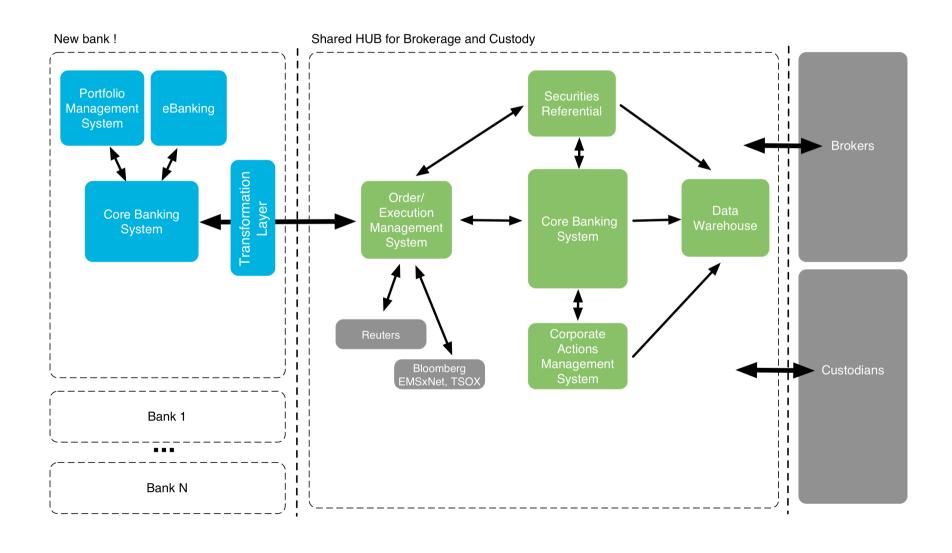




### Cyril PICAT

OCTO Technology Lausanne, consultant

# Le projet : migration d'une banque vers une nouvelle plateforme titres



## Quelques chiffres

Clients: x10

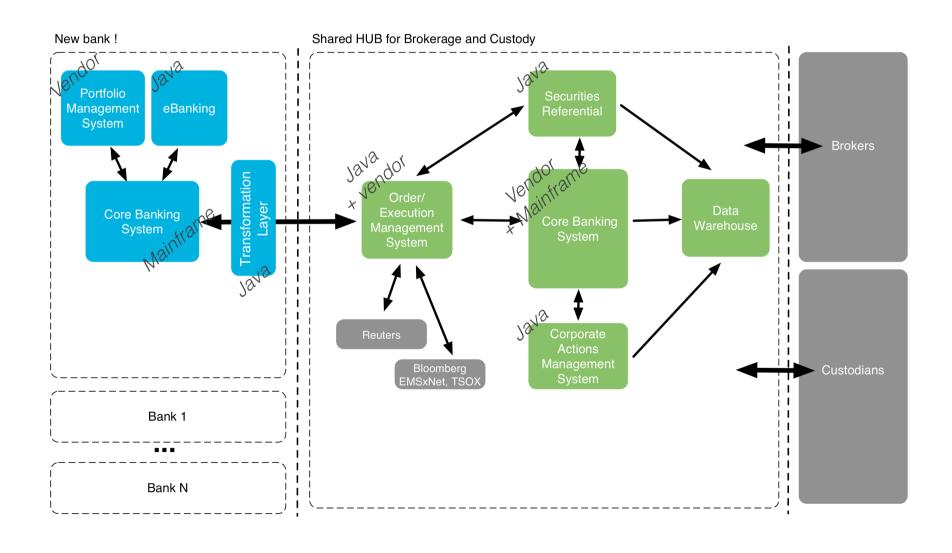
Portefeuilles titres: x5

Positions: x3

Titres: +50%

Ordres de Bourse: x2

# Le projet : migration d'une banque vers une nouvelle plateforme titres



Autant attendre la mise en production...

### Méconnaissances

Nier l'existence du problème	On a bien travaillé, ça va passer
Nier l'existence de solutions	C'est impossible à tester sauf en prod
Nier la fiabilité des solutions	La charge ne sera pas représentative
Mettre en doute ses capacités	On n'y arrivera jamais

# ldées reçues sur les pré-requis

- Une pré-production identique à la production
- Simuler l'ensemble des activités de la banque

# ldées reçues sur les tests de charge

Tester en automatique ? Impossible même avec <un nom de produit ici>

# Idées reçues sur le diagnostic

Les problèmes sont sur le mainframe

# Ce sont des idées reçues

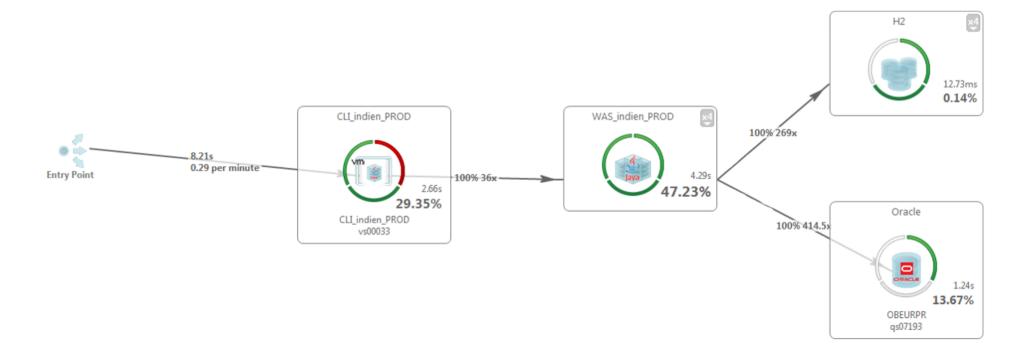
#### Notre objectif, vous montrer

- comment adapter vos pré-requis à vos enjeux
- comment aborder les tests de charge dans un SI
- comment ne pas être piégé par les diagnostics préconçus

### Dans un monde parfait...

"Fais de ta vie un rêve, et d'un rêve une réalité." Antoine de Saint-Exupéry - Cahiers de Saint-Exupéry (1900-1944)

# Rêve : une vue intégrée de la performance





### Réalité : Qui le fait au niveau d'un SI?

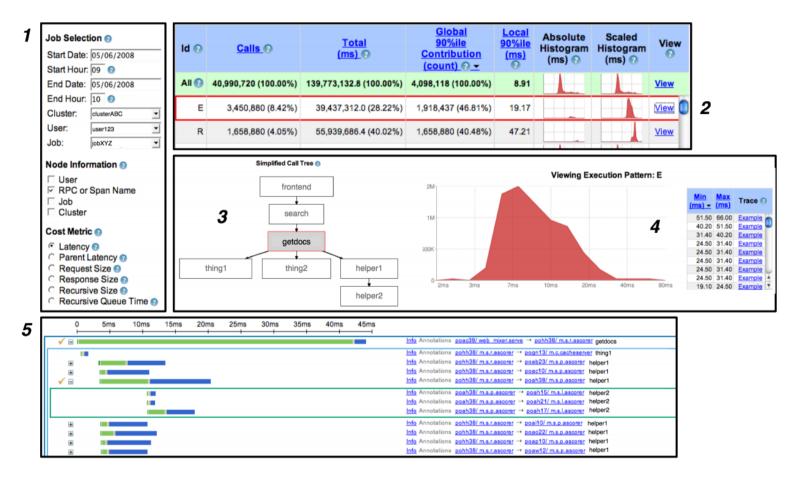


Figure 6: A typical user workflow in the general-purpose Dapper user interface.

# Réalité : Commencer par des outils simples

Analyse de logs (python, pandas...)



Collecte d'outils systèmes (nmon, vmstat...)



# Rêve : Tout ce qu'il faut pour faire les tests

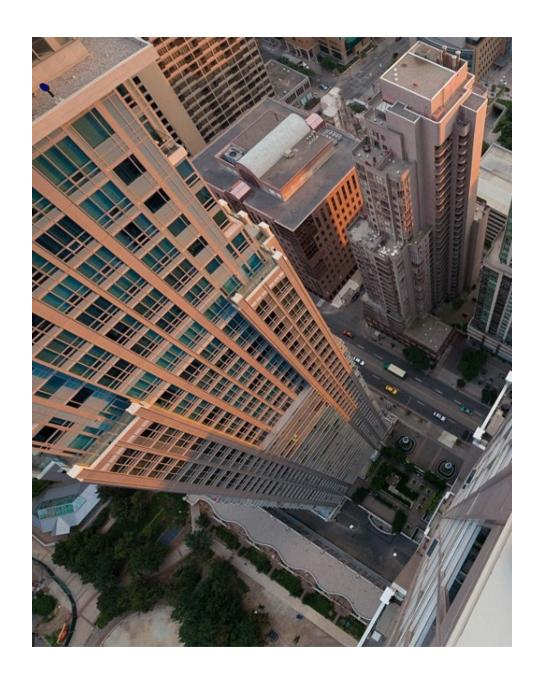
- Des développements terminés
- Des données migrées
- Des personnes disponibles.... et colocalisées

# Réalité : Les intangibles

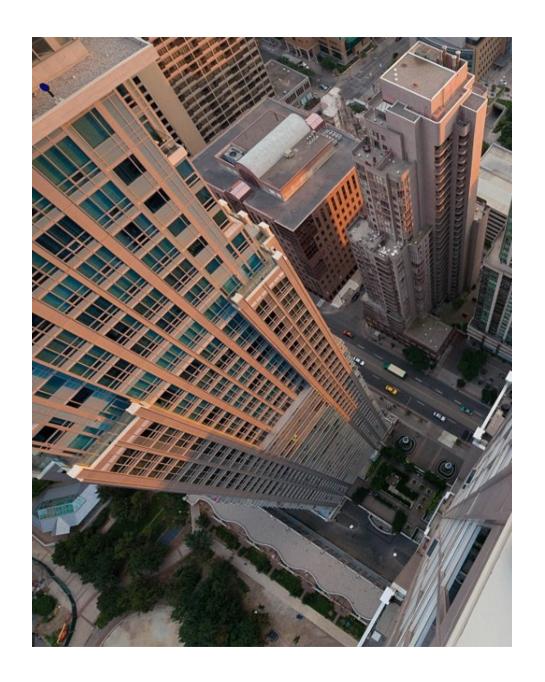
- Un environnement opérationnel
- Un jeu de données minimal
- Une zone de mesure isolée

Pour le reste...

Savoir fixer ses priorités



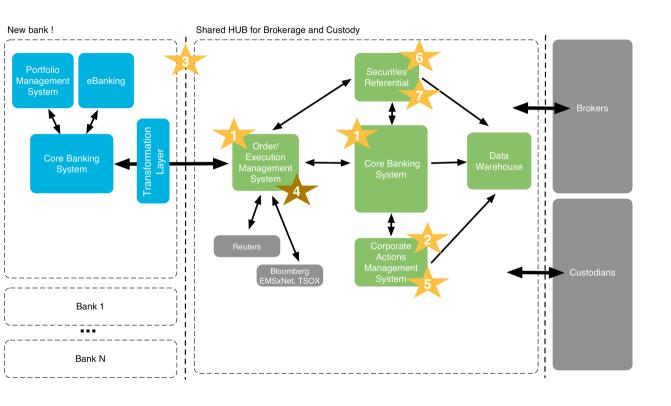
Les problèmes peuvent sembler vertigineux



# Il faut "cadrer" le chantier

- Factualiser les volumes existants et cibles
- Lister les problèmes existants
- Brainstormer sur les problèmes potentiels

#### Les problèmes "usuels"



- Capacité en terme de nombre de transactions/jour
- 2. Augmentation de **volumétrie** (x2)
- 3. **SLA** temps de réponse end-to-end
- 4. Lenteurs actuelles
- 5. Augmentation du **nombre d'utilisateurs**
- 6. Impact sur la durée des batchs
- 7. **Latence et temps de réponse** pour les utilisateurs distants

#### Et ensuite?

La carte vous aide à visualiser et à prioriser, elle ne "résout" pas les problèmes

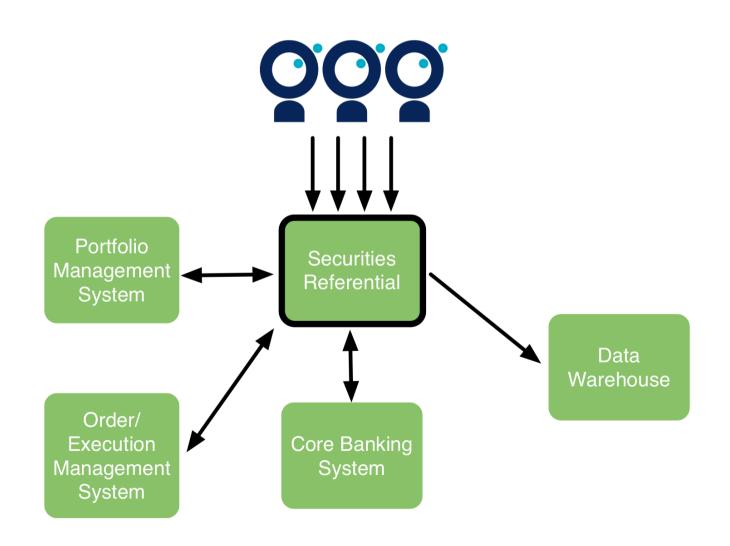
Chaque problème reste complexe et lié au reste du SI

### Diviser pour mieux régner

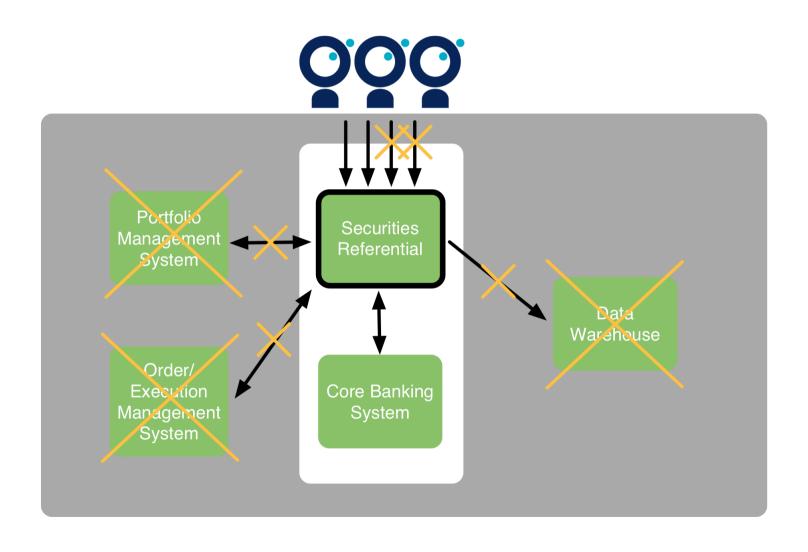
#### 2 patterns

- **Diviser/découpler**: passer d'un test de N systèmes à un test de k<N systèmes (idéalement 1)
- **Simplifier** : réduire la dimensionnalité (cas de tests, données etc.)

# Diviser/découpler : un exemple



### Diviser/découpler : un exemple



#### Et maintenant?

Ne prévoyez pas un test de charge pour tous les problèmes!

#### Penser à d'autres outils



Analyse de l'existant



Modélisation et extrapolation



Test de charge de l'existant (données, systèmes)



Test de charge de la cible (données, systèmes)

### Où pouvez-vous vous "planter"?

Mauvaise connaissance de la performance existante Mauvaise connaissance des usages existants

# Bonnes pratiques de tests de charges (application par application)

### Délimiter le périmètre testé

- Car un test de charge reste un test automatisé
- Car un test en erreur ne sert à rien

#### Comment?

- Choisissez soigneusement votre jeu de données
- Ou développez des bouchons

## **Bouchonner**

- Les composants utilisés systématiquement
- Le plus simplement possible

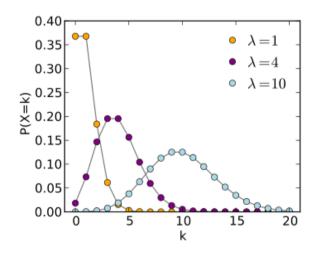
## Modéliser scientifiquement

Modéliser le comportement de mes utilisateurs?

- Combien d'utilisateurs simultanés?
- Qu'est-ce qu'un utilisateur simultané?

# Modélisation scientifique

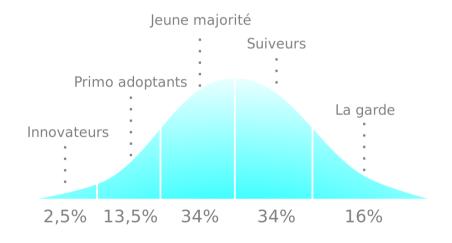
- La vérité est en production
- Un modèle : moyenne ET percentile 99th



Exemple de lois de Poisson

# Modélisaton : soyez prédictifs

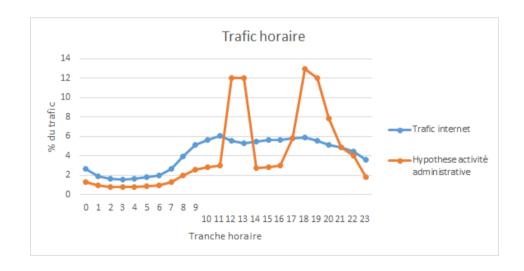
Si vous n'avez pas de statistiques production, proposez un modèle de prévision du nombre d'utilisateurs



Cycle de diffusion de l'innovation

## Modélisation : soyez prédictifs

Si vous n'avez pas de statistiques production, proposez un modèle de prévision de leur utilisation





# Définissez dans vos tests d'injection locaux le nombre d'utilisateurs "simultanés" et le temps de réflexion

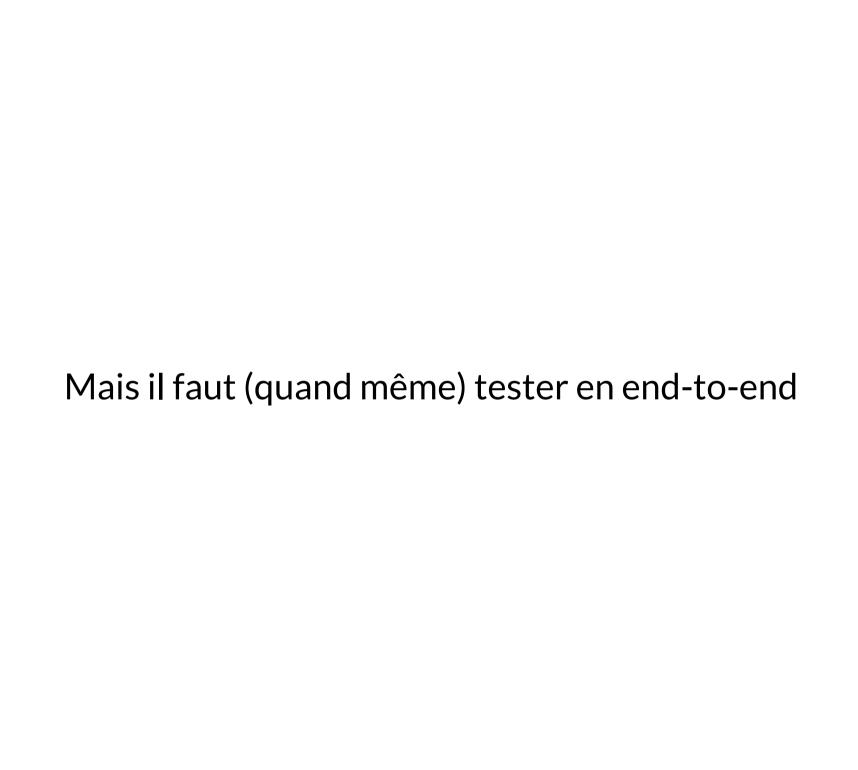
```
val clientSearchChain = group("client_search_page") {
    exec(http("client_search_html")
        .get("""/ebankingAdmin/xxxxx/root/contract/contractlist/""")
}
).pause(7,8) //Pause between 7 and 8 seconds

val scn = scenario("AdminSimulation").repeat(1) {
    exitBlockOnFail {
        exec(loginChain).exec(clientSearchChain)//No logout, 90% of use
rs don't
      }
}
setUp(scn.inject(rampUsers(120).over(60))).protocols(httpProtocol) //Th
is will go from 0 to 120 users in 60 seconds
```



Une brique de base de la performance du SI

Comment fait-on pour manger un éléphant ? Bouchée par bouchée.



# DEMO Quizz : quel est le temps de réponse d'une application ?

70 ms. de traitement

7 appels en base de données, 14 ms. chacun

```
curl -X POST \
-H "Accept: applicaiton/json" \
-H "Content-Type: application/json" \
-d '{"cpuIntensiveComputationsDuration":70, "databaseCallsNumber":7, "d atabaseCallDuration":14 }' \
http://$HOST:8080/compute
```

#### Temps de réponse ~ 190 ms.

```
$ ./sh/pocl.sh
% Total % Received % Xferd Average Speed Time Time C
urrent
Dload Upload Total Spent Left Speed
100 253 100 161 100 92 789 450 --:--:-- --:---
- 789
Call HTTP Ressources : For an HTTP ressources total of 0.0 ms.
Call the database 7 times during 14 ms. each for a total of 118 ms.
CPU intensive compute 186 ms.
```

#### Détail de l'exécution

```
10-18 16:32:22 jdbc:
/**/CallableStatement call98 = conn7.prepareCall("call sleep(?)");
10-18 16:32:22 jdbc: SESSION PREPARE READ PARAMS 30
10-18 16:32:22 jdbc:
/**/call98.setLong(1, 14L);
10-18 16:32:22 jdbc:
/**/call98.execute();
10-18 16:32:22 jdbc: COMMAND EXECUTE QUERY 30
10-18 16:32:22 jdbc: RESULT CLOSE 31
10-18 16:32:22 jdbc:
/**/call98.close();
10-18 16:32:22 jdbc: COMMAND CLOSE 30
10-18 16:32:22 jdbc:
/**/conn7.getAutoCommit();
10-18 16:32:22 jdbc:
/**/conn7.getWarnings();
```

# DEMO & Quizz : quel est le temps de réponse d'une chaîne applicative dans un SI ?

7 applications identiques à la précédente (70 ms. de traitement, 7 x 14 ms. de BD)

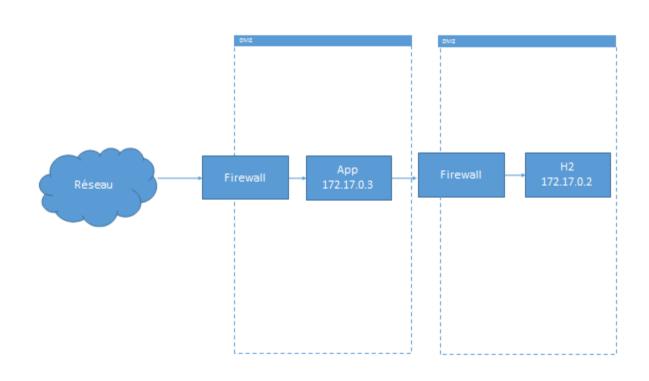
Appels synchrones séquentiels

```
curl -X POST \
-H "Accept: applicaiton/json" \
-H "Content-Type: application/json" \
-d '{"cpuIntensiveComputationsDuration":70, "databaseCallsNumber":7, "d atabaseCallDuration":14, "serviceCalls":[{"computationDescription":{"cpuIntensiveComputationsDuration":70, "databaseCallsNumber":7, "databaseCallDuration":14}, "callsNumber":6 }]}' \
http://$HOST:8080/compute
```

#### Temps de réponse : 1 s.

```
$./sh/poc2.sh
 % Total
            % Received % Xferd Average Speed
                                               Time
                                                       Time
                                                                Time
Current
                                Dload Upload
                                               Total
                                                       Spent
                                                                Left
Speed
                                        185 0:00:01
100 1417
          100 1171 100 246
                                  881
                                                     0:00:01 --:--
   881
Call HTTP Ressources : {
       Call HTTP Ressources: For an HTTP ressources total of 0.0 ms.
       Call the database 7 times during 14 ms. each for a total of 113
ms.
       CPU intensive compute 68ms.
{,
       Call HTTP Ressources: For an HTTP ressources total of 0.0 ms.
       Call the database 7 times during 14 ms. each for a total of 114
```

DEMO & Quizz : quel est le temps de réponse de la même chaîne dans une modélisation plus proche de la réalité ?

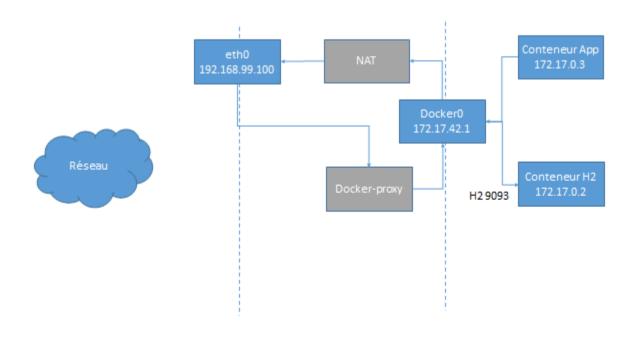


### Implémentation de ce Quizz

Diokles: An Information System scale performance simulator

https://github.com/mbojoly/diokles

(https://github.com/mbojoly/diokles)



\$ sudo docker-machine ssh default

delay 10ms

\$\$ sudo tc qdisc add dev docker0 root netem

\$\$ sudo tc qdisc show dev docker0

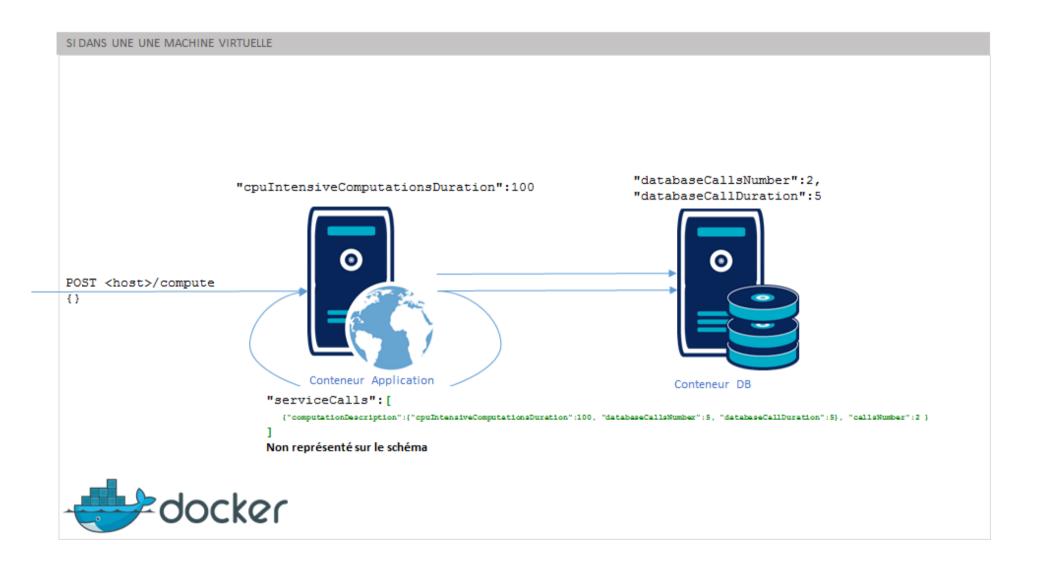
\$\$ #After demo

\$\$ sudo tc qdisc del root dev docker0

#### Temps de réponse : 3 s.

```
$ ./sh/poc2.sh
                           % Total % Received % Xferd Average Spee
d
   Time
           Time
                    Time
                          Current
                           Dload Upload Total Spent Left Spee
d
                           100 1417 100 1171 100 246
                                                             328
  0:00:03 0:00:03 --:--
                              328
                           Call HTTP Ressources : {
                           Call HTTP Ressources : For an HTTP ressourc
es total of 0.0 ms.
                           Call the database 7 times during 14 ms. eac
h for a total of 394 ms.
                           CPU intensive compute 69ms.
                           {,
                           Call HTTP Ressources : For an HTTP ressourc
es total of 0.0 ms.
```

#### L'outil utilisé





#### Des problèmes "mineurs" peuvent devenir critiques à l'échelle d'un SI

- Latence
- N+1 SQL requêtes
- N+1 appels à des applications externes

Les tests "end-to-end" sont obligatoires car certains résultats peuvent défier l'intuition

#### Boîte à outils pour les tests "end-to-end"



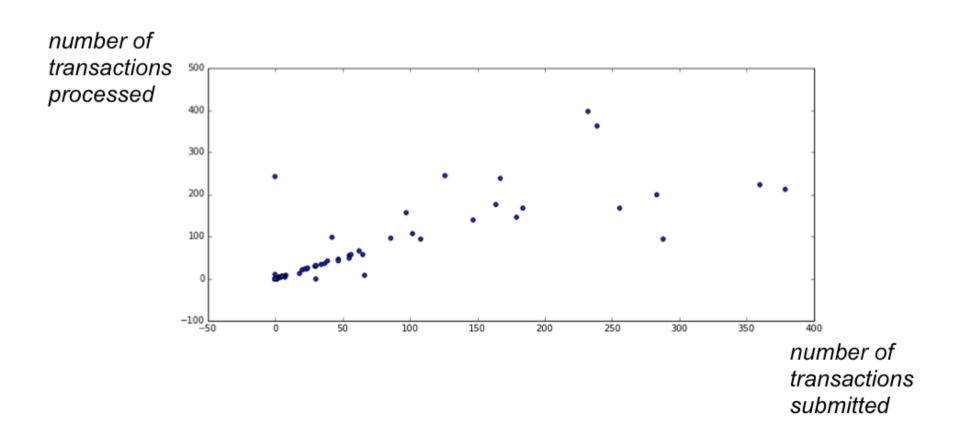
Les tests end-to-end sont complexes. Ceci ne se veut pas une méthode systémique mais un inventaire d'outils à disposition, ainsi qu'un REX sur leur efficacité

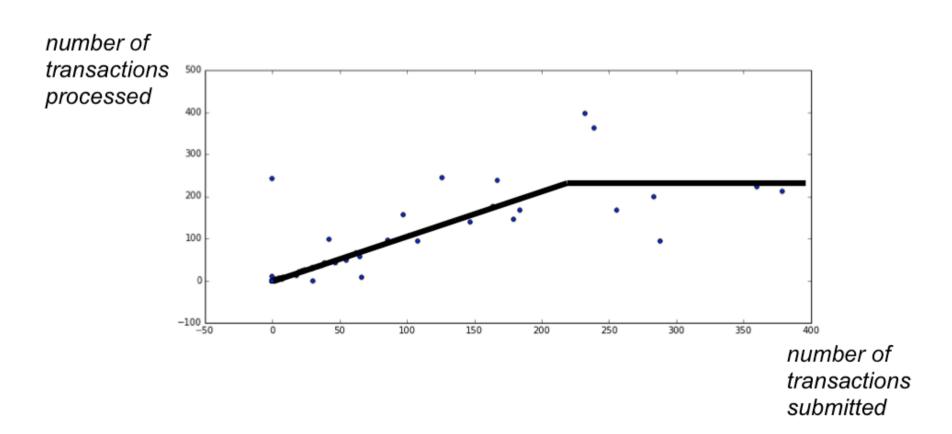
Analyse des latences entre systèmes

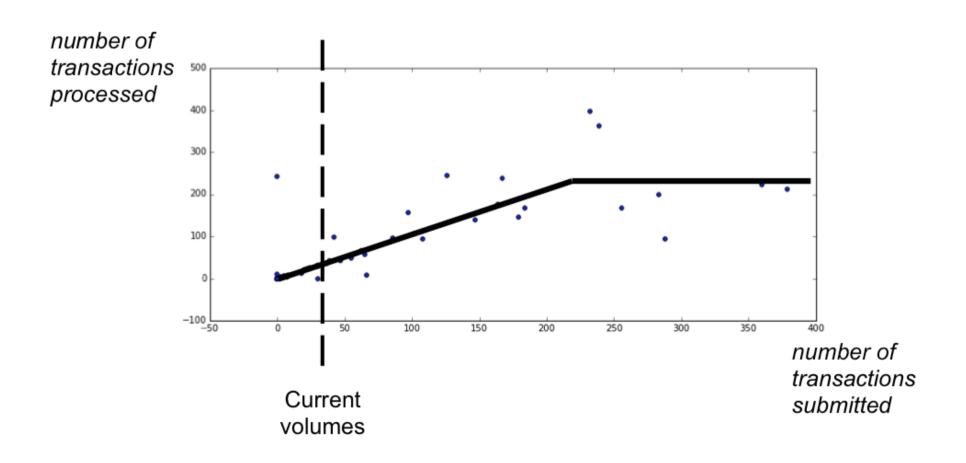
Identification du goulet d'étranglement

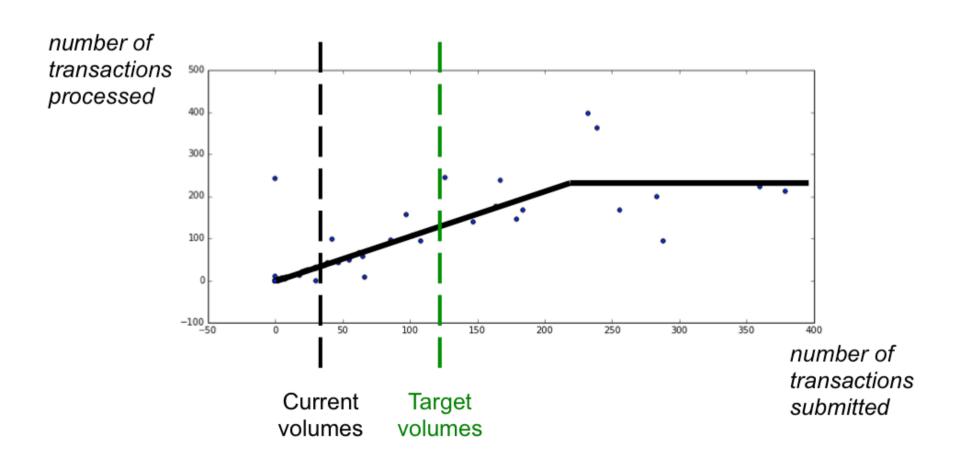
Découverte des problèmes de design

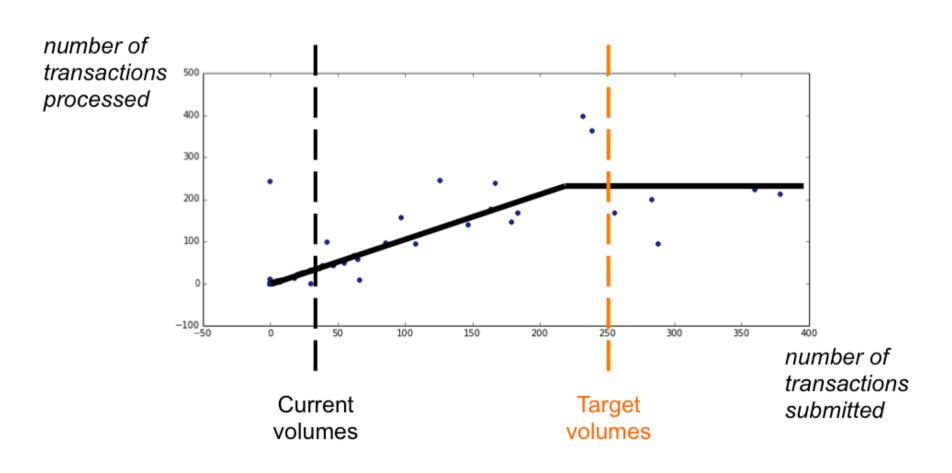
Évaluation de la capacité du système







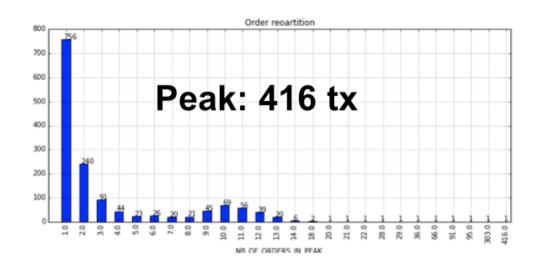


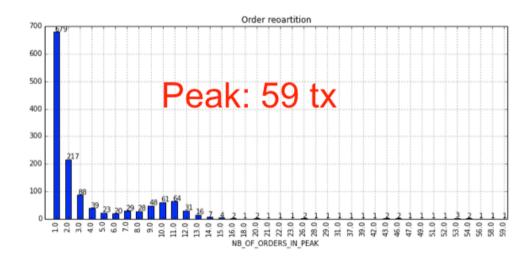


#### Outil #1: attention aux chiffres!

Volume	Temps de réponse moyen
1000 transactions	15s
2000 transactions	40s

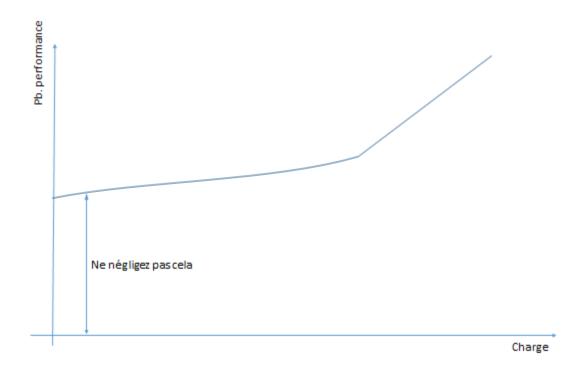
#### Outil #1: attention aux chiffres!





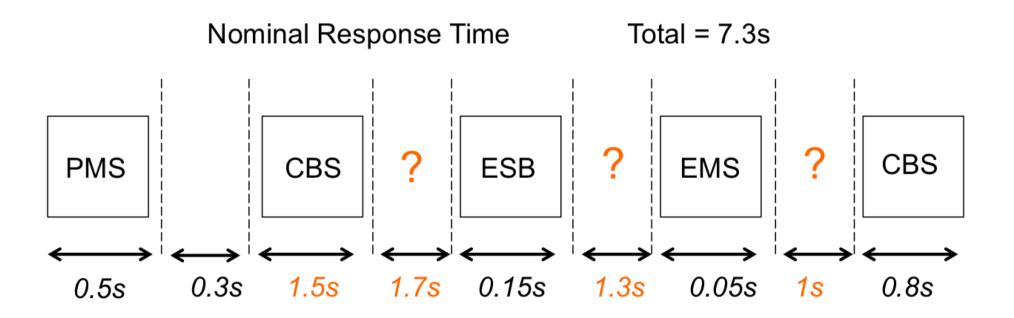
#### Outil #2: Benchmark unitaire

Définition : mesure de la réponse à une transaction unitaire



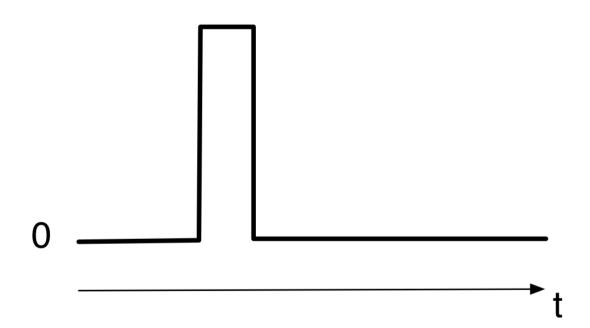
#### Outil #2: Benchmark unitaire

#### Exemple d'analyse



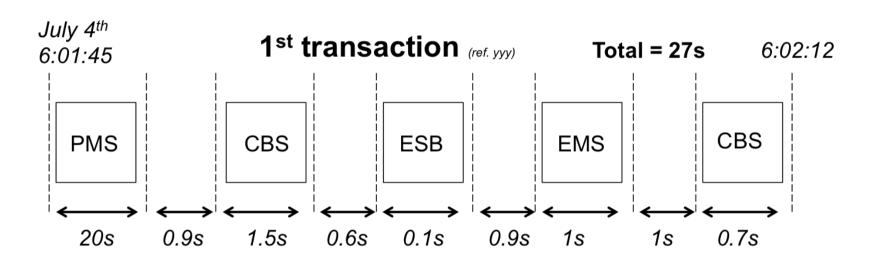
## Outil #3 : le pic de transactions

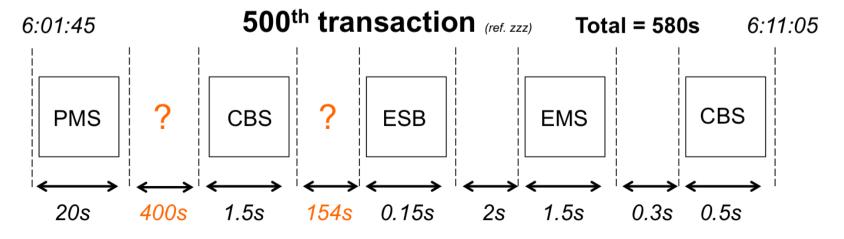
#### N transactions



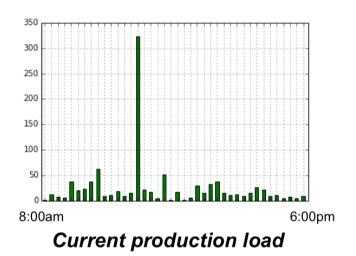
#### Outil #3 : le pic de transactions

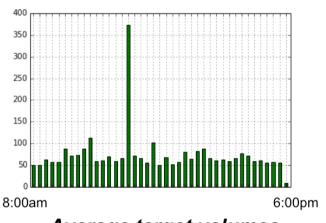
#### Exemple d'analyse



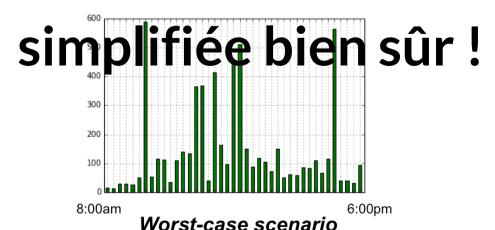


# Outil #4 : "rejeu" d'une journée de production





Average target volumes



#### Outil #5: mettre en production

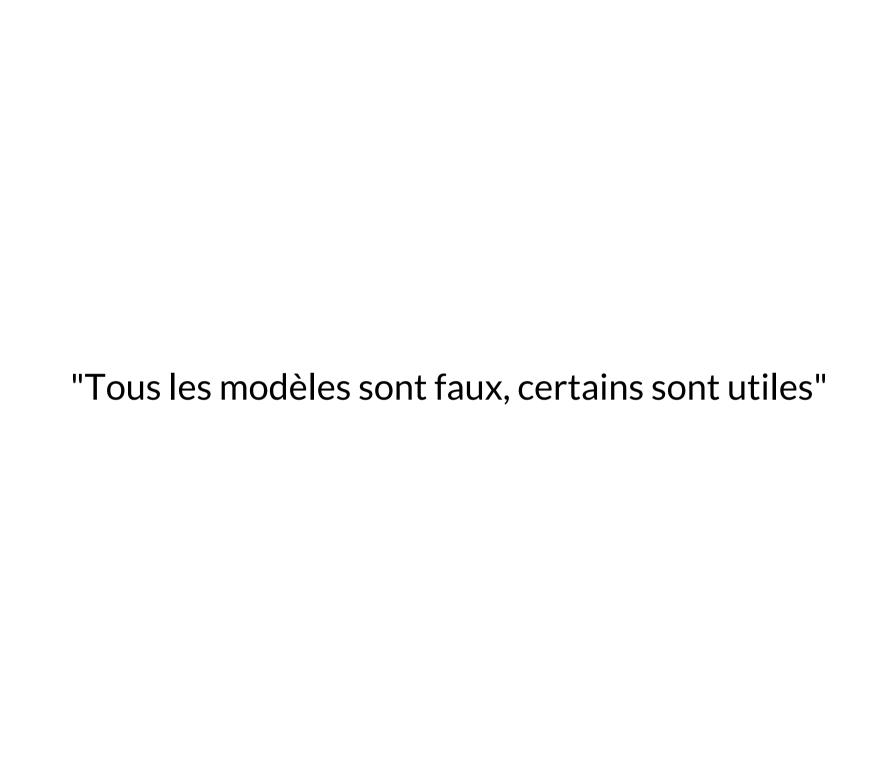
Tout ce qui peut être mis en production par avance doit l'être

Pensez votre stratégie de migration pour monter en charge progressivement

Inspirez-vous des "Géants du Web"

# Take-away

- Faites des tests, même imparfaits
- Mesurez scientifiquement
- Revenez-en à des problèmes simples
- Extrapolez, en ayant conscience des limites



#### Si cela vous a intéressé



recrutement@octo.com

#### Sources

Tous les slides : icônes (c) OCTO Technology (2015)

Autant attendre la mise en production : Morguefile (http://www.morguefile.com/archive/display/940045)

Vivre ses rêvess : ginacn.blogspot.fr (http://ginacn.blogspot.fr/2006/05/petites-estrelles.html) et Wikipedia (https://en.wikipedia.org/wiki/Antoine de Saint-Exup%C3%A9ry)

APM: Outil Dynatrace (http://www.dynatrace.com/fr/index.html)

Google Dapper: Dapper, a Large-Scale Distributed Systems Tracing Infrastructure (http://static.googleusercontent.com/media/research.google.com/fr//pubs/archive/36356.pdf)

Bonnes pratiques : Géants du Web, l'obsession de la mesure (http://www.octo.com/fr/publications/11-les-geants-du-web)

Exemples de lois de poisson : Wikipedia (https://fr.wikipedia.org/wiki/Loi\_de\_Poisson)

(https://fr.wikipedia.org/wiki/Loi\_de\_Poisson)

(https://fr.wikipedia.org/wiki/Loi\_de\_Poisson)Cycle de diffusion de l'innovation : Wikipedia (https://fr.wikipedia.org/wiki/Everett\_Rogers)

Traffic sur Internet: Libstat (http://www.libstat.com/pages/heure.htm)

Tests end-to-end: Youtube: Spectacular Domino Rally Stunt Screen Link 4:51 (https://www.youtube.com/watch? v=7BVr6LaC HQ)

Tous les modèles sont faux certains sont utiles : Morguefile (http://www.morguefile.com/archive/display/940045)